



Introduction à la reconnaissance des formes et au *Machine Learning*

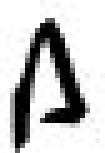
Omar Galarraga, *Ph.D.*omar.galarraga@ugecam.assurance-maladie.fr

Pattern Recognition & Biometrics Prof. Sonia García (*coord.*) 2023-2024

Qu'est-ce que la reconnaissance des formes et le *Machine Learning*?











La reconnaissance des formes et le *Machine Learning*

- Trouver des relations significatives entre les données pour la prise de décision
- Apprentissage automatique / apprentissage statistique
- Rendre les machines capables d'apprendre des tâches « humaines »
- Estimation / Filtrage / Prédiction
- Classification / Régression



Applications : reconnaissance des caractères manuscrits

Service postal

Numérisation de documents



Paleston Peoples Party

To the official and members of Paleston
Peoples Party 3 and that I was homoving to their
you. He haden could be as proud by them purity,
then dedication, doorstom and dissiplines to the
mission of head a Diem Zulfishen Die Blutte for
a Federal Domocratic and Egilitarion Paleston
as 3 have been proud by you. I salute
upon toways and your serve of homour.
Be salute you for shouting by your sinter
through this military duction things.
I feer for shouting by your sinter
through the fight against extremisms, distribute
priesty and of archae.

I would see my hurband this Ali Dulan
to lead you in this Interior party until you
and he blewste what is hert. I say Then
because he is a man of courage and huran.
He spent "//2 years in prison without
should deep be fortune. It has the palatical
alsolve to keep our party units
I wish all by your success or fulfilling
the manifests of our party and to
serving the drivative delay their minates and
epprovised people of Paleston. Dedicate
fewerthers to free by them from provery and
business of heavily them from provery and



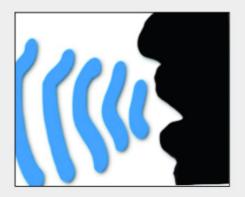
Applications : Biométrie

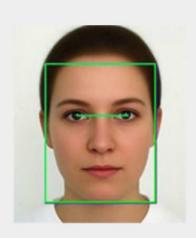








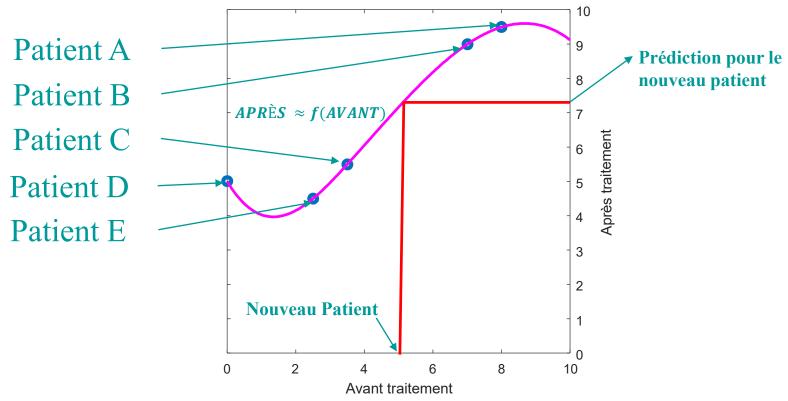






Apprentissage supervisé

- Classes / valeurs de sortie désirée connues
- Objectif : minimiser l'erreur entre la sortie désirée et la sortie estimée





Exemple: reconnaissance du visage













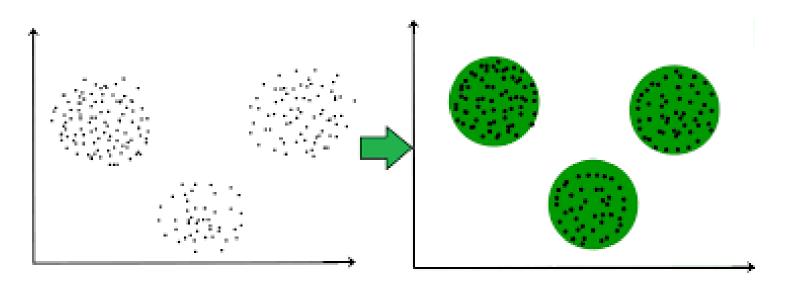




Apprentissage non supervisé

- Données non étiquetées
 - Classes inconnues
 - Valeurs de la sortie désirée inconnues

Clustering





Etapes du Machine Learning

Prétraitement

Extraction des caractéristiques

Classification / Régression



Autres paradigmes d'apprentissage

Apprentissage profond

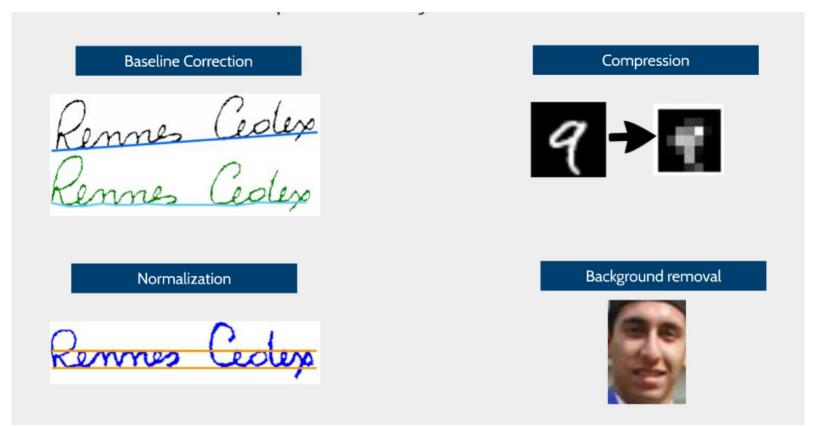
Apprentissage par renforcement

Apprentissage auto-supervisé



Prétraitement

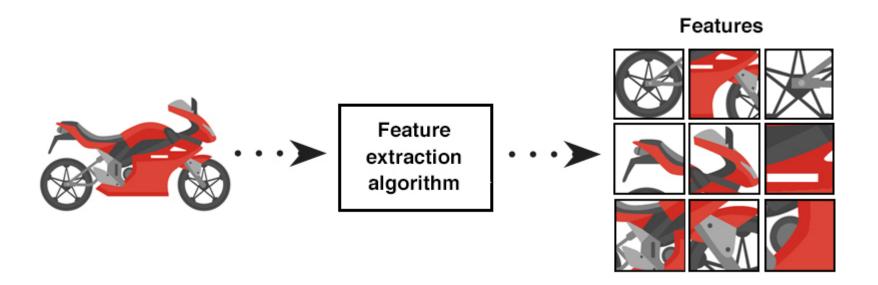
■ Préparer, « nettoyer » les données





Extraction des caractéristiques

Variables importantes, prédictives

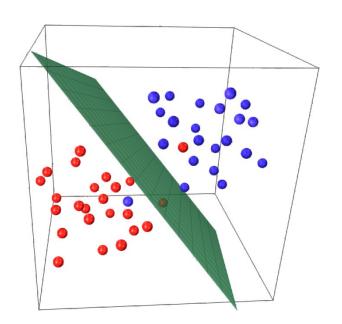




Classification vs Régression

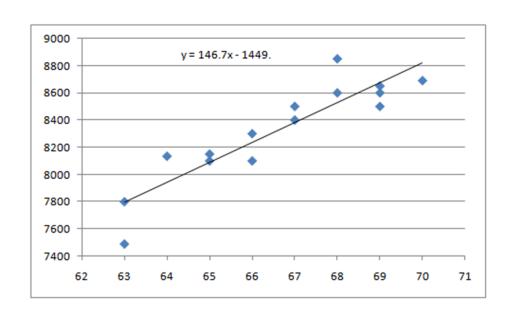
Classification

Catégories (sortie discrète)



Régression

Sortie continue





Classification Naïve Bayésienne

■ Etant donné $x = (x_1, \dots, x_l)^T$ un vecteur de caractéristiques pouvant appartenir à des classes c_{1,\dots,c_K}

■ $P(c_1|x), \dots, P(c_K|x)$ probabilités « a posteriori »

 argmax[P(c_i|x)] nous donnera la classe la i=1,···,K
 plus probable d'appartenance pour x



Règle de décision : 2 classes

$$P(c_i|x) = \frac{P(x|c_i)P(c_i)}{P(x)}$$

L'observation x sera affecté à la classe c_a avec :

$$a = \begin{cases} 1 \sin P(c_1|x) > P(c_2|x) \\ 2 \sin P(c_1|x) < P(c_2|x) \\ 1 \text{ ou } 2 \sin P(c_1|x) = P(c_2|x) \end{cases}$$





Estimation de la probabilité conditionnelle

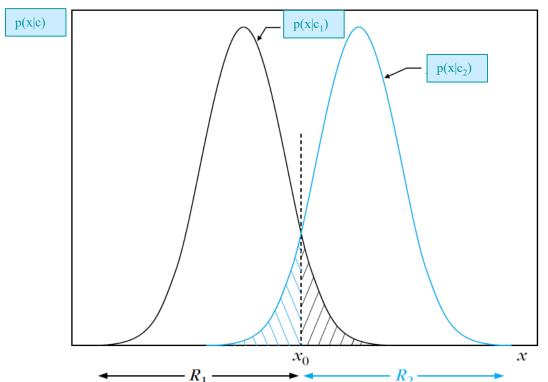
■ Si les variables $x_j \forall j = 1, \dots, l$ sont « normales » et indépendants

$$P(x|c_i) = \prod_{j=1}^{l} \frac{1}{\sqrt{2\pi\sigma_{j,i}^2}} e^{-\frac{(x-\mu_{j,i})^2}{2\sigma_{j,i}^2}}$$

Si
$$l = 1 \rightarrow \frac{P(c_1)}{2\pi\sigma_1^2} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \le \frac{P(c_2)}{2\pi\sigma_2^2} e^{-\frac{(x-\mu_2)^2}{2\sigma_2^2}}$$



Risque d'erreur (minimum)

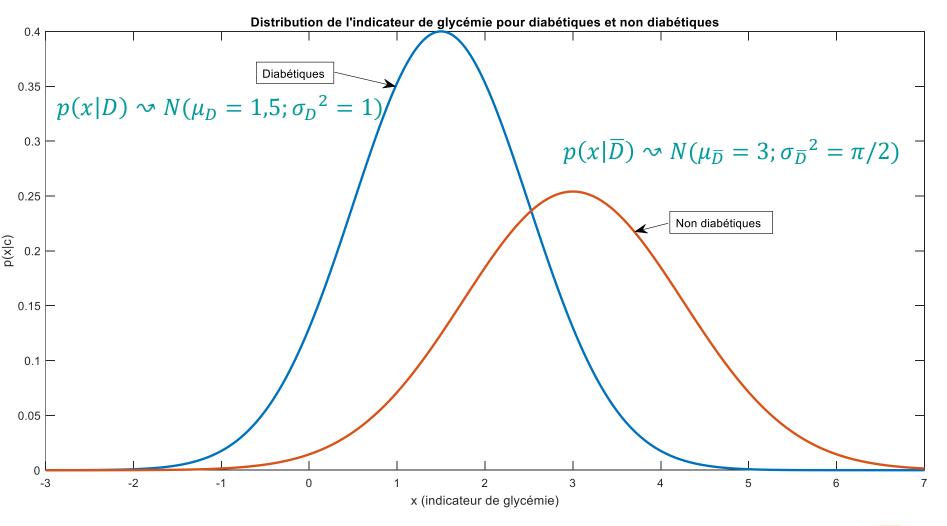


Source: Koutoumbras & Theodoridis (2009)

$$P(Erreur) = P(c_2) \int_{-\infty}^{x_0} p(x|c_2) dx + P(c_1) \int_{x_0}^{\infty} p(x|c_1) dx$$



Exemple: détection du diabète





$$P(D) = 0.1689 \ et \ P(\overline{D}) = 0.8311$$

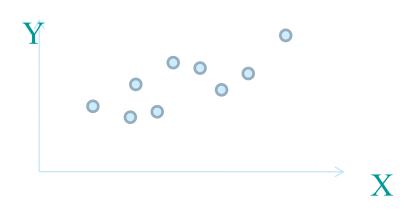
Régression

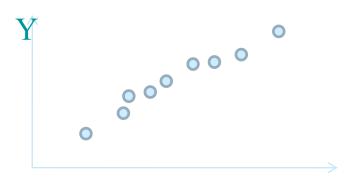
- Modéliser la relation entre deux (ou plus) variables (continues)
- Estimation, filtrage, prédiction...
- Types:
 - Linéaire
 - Multilinéaire
 - Non linéaire
 - Etc...



Régression linéaire simple

- Cas de deux variables quantitatives
 - X : facteur ou variable indépendante fixée par l'expérimentateur
 - Y : réponse ou variable dépendante
- Dispersion







Modèle linéaire

$$y = ax + b + \varepsilon$$

$$\hat{y} = ax + b$$

On veut minimiser l'erreur

$$J(a,b) = \sum_{i=1}^{n} (y_i - ax_i - b)^2$$



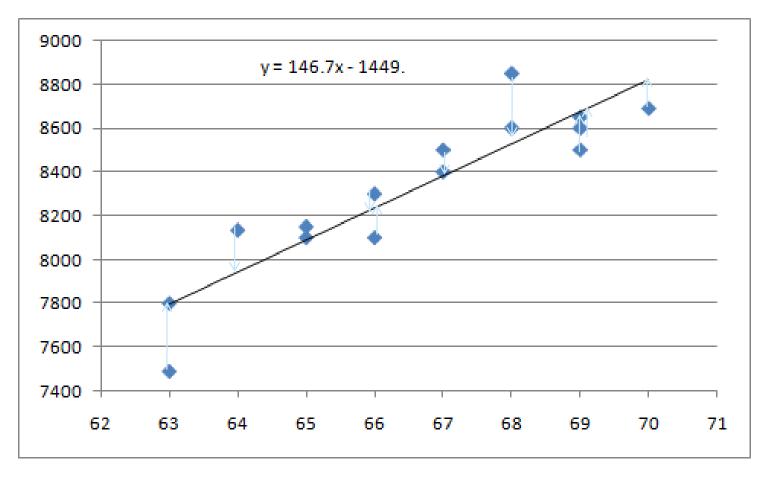
Solution des moindres carrés

$$a = \frac{Cov(x,y)}{S_x^2} = r_{xy} \frac{S_y}{S_x}$$

$$b = \bar{y} - a\bar{x}$$



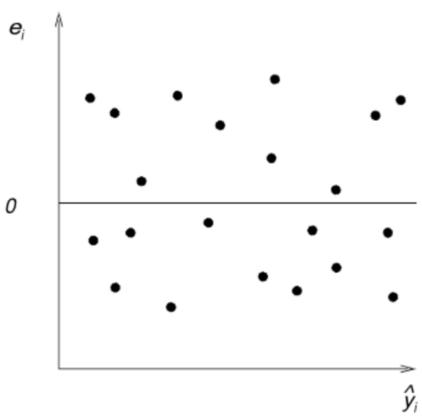
Résidus





Graphique des résidus

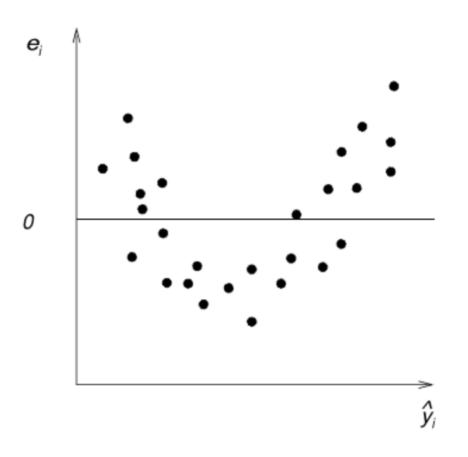
Convenable:





Analyse des résidus

Le modèle linéaire n'est pas approprié :





Régression multilinéaire

$$Y = AX + \epsilon$$

$$A = YX(XX^T)^{-1}$$

$$Y = \begin{pmatrix} y_{1,1} & \dots & y_{1,n} \\ \vdots & \ddots & \vdots \\ y_{N_{out},1} & \dots & y_{N_{out},n} \end{pmatrix}$$

$$X = \begin{pmatrix} x_{1,1} & \dots & x_{1,n} \\ \vdots & \ddots & \vdots \\ x_{N_{in},1} & \dots & x_{N_{in},n} \\ 1 & \dots & 1 \end{pmatrix}$$

$$A = \begin{pmatrix} a_{1,1} & \dots & a_{1,N_{in}+1} \\ \vdots & \ddots & \vdots \\ a_{N_{out},1} & \dots & a_{N_{out},N_{in}+1} \end{pmatrix}$$



Régularisation

Pour limiter l'impact des « outliers »

$$J(A) = \sum_{i=1}^{n} (y_i - Ax_i)^2 + \lambda \sum_{j=1}^{N_{out}} \sum_{k=1}^{N_{in}} (A_{j,k})^2$$



Evaluation de la performance du modèle

Classification

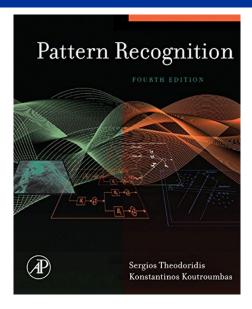
- Matrice de confusion
- Prévalence (Accuracy)
- Sensibilité
- Spécificité
- Entropie croisée (binaire)

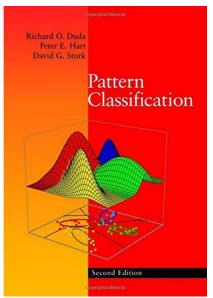
Régression

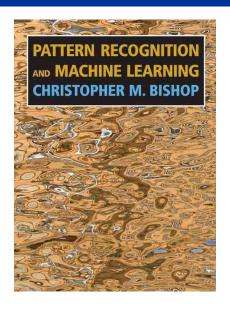
- Erreur quadratique moyenne (MSE)
- Root-MSE (RMSE)
- Ecart moyen (MAE)
- Coefficient de détermination (R²)

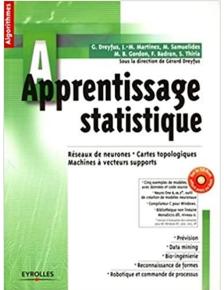


Lectures pour approfondir











MOOCS

Machine Learning in Python with sci-kit learn. FUN-MOOC. INRIA.

- Machine Learning. COURSERA. Deep.Al Andrew Ng
- Deep Learning for Coders. FAST.AI
- From Deep Learning to Stable Diffusion. FAST.AI
- Deep Learning Specialization. Deep.Al (COURSERA). [Plusieurs cours payants].

